附件：

面向城市场景的视觉多模态目标检测技术报告

苏大一队　刘志轩　朱文楦　孙延

AIC-2026-19640904　半决赛　线上 56.132

一、算法概述

本方案面向城市场景的 12 类目标检测，使用 RGB、红外和深度三种传感信息，应对光照变化、远距离目标和遮挡带来的识别困难。算法以 RF-DETR 2XL 为基础，建立独立的三模态特征分支，通过 OPF 先融合 Depth、再融合 IR；使用单模态教师的 EMA 参数初始化辅助分支，并控制持续蒸馏强度。前期架构搜索确定 RGB 窗口 W4、IR 窗口 W2、Depth 窗口 W4、4 层有效解码输出、300 个查询与 1 层 OPF，输入分辨率为 880×1600。训练采用 2000 张标注样本、类别均衡重采样、同步几何增强、RGB 低照增强、HBS 背景平滑双视图监督及 EMA。学生完成 64 轮全量训练后，选择 epoch47 的 EMA，使用同一模型进行整图与四切片 G6 推理，统一置信度 0.25、每图最多 100 框。该提交在半决赛线上取得 56.132。作品提供代码、固定配置、学生权重、原始结果和校验记录，重点保证数据语义、多模态训练和推理复现的一致性。

二、实现方案

2.1 数据预处理与模态配对

训练使用赛题 2000 组三模态图像及配套标注，按同名标识配对 RGB、IR、Depth 与 YOLO 标签，类别编号为 0 至 11。样本加载时检查标签范围、坐标和模态覆盖。半决赛测试集为 1000 组，包含新的光照、密集人群和尺度分布；测试图像仅用于预测，没有用于训练、伪标签或目标域适配。

深度图兼容 16 位毫米距离与 8 位近远灰度表示。前者转换为近距离更强的归一化值，后者直接按灰度语义归一化，避免重复取倒数。深度值、有效性、格式指示和质量构成 5 通道输入，经可学习投影送入 Depth 分支；有效性与质量信息参与融合或蒸馏掩码。RGB、IR 和 Depth 共享缩放、裁剪、翻转参数，保持跨模态几何一致。

2.2 三模态特征融合与固定结构

三条独立 RF 视觉分支分别提取 RGB、IR 和 Depth 特征。RGB 采用 W4 窗口，IR 采用 W2，Depth 采用 W4；辅助特征经 OPF 顺序注入 RGB 主路，融合顺序为 RGB 与 Depth、再与 IR。融合特征进入原生 RF 检测模块，使用 300 个查询。最终选择第 4 层解码输出及前 3 层辅助监督；实现保留原生 5 层参数，不把这一选择错误描述为已物理裁掉全部后缀参数。

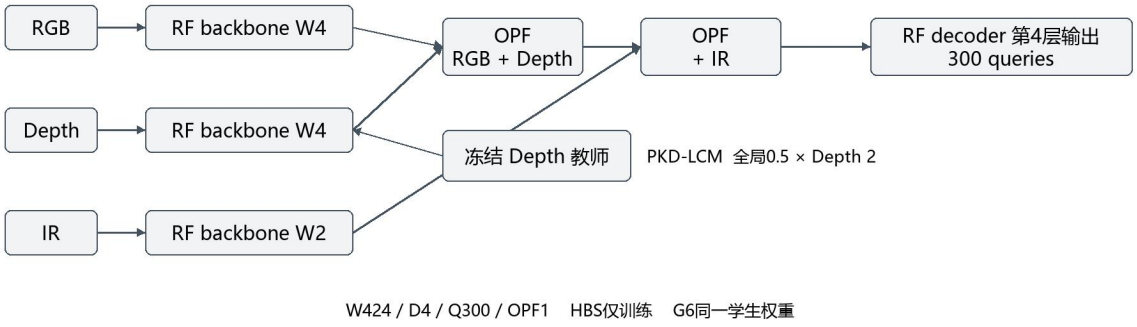


图 1 最终三模态检测流程 HBS 与教师监督仅用于训练

结构搜索结果用于固定最终网络，正式全量运行不再随机采样架构。强制配置为 W424、D4、Q300、OPF1、880×1600。IR 持续蒸馏权重为 0 仍保留 IR 输入、独立分支、教师初始化和特征融合，模型始终为三模态。

2.3 教师初始化与受控蒸馏

IR 教师训练 38 轮，Depth 教师训练 49 轮，分别使用 epoch37 与 epoch48 EMA 初始化学生辅助分支。两个教师和学生的全量阶段均只使用赛题训练数据。持续蒸馏采用 PKD-LCM 配置，全局系数 0.5，IR 系数 0，Depth 系数 2；完成蒸馏预热后，Depth 名义总系数为 1。前景权重为 2，适配器缩减比为 16，使用深度有效性掩码，跨模态蒸馏系数为 0。

初始化与持续约束分别控制，使 IR 提供已学表示并保留联合训练自由度。部署时直接加载完整学生 EMA，既不加载教师，也不运行蒸馏损失；推理入口同时跳过官方预训练加载，避免评审运行时依赖原服务器路径。

2.4 HBS 与 RGB 低照增强

HBS 借鉴 SET 的背景平滑思想，在 512 通道 OPF 融合特征上构建训练分支。由训练标注生成前景保护掩码，并向外扩展一个特征网格以保护目标边界；仅背景区域经降维卷积、激活和恢复通道卷积处理，输出卷积零初始化。原始视图与 HBS 视图共享检测器，检测损失分别乘 0.5，再结合蒸馏项优化。该实现未启用 SET 中的 API 分支，不能视为完整 SET 复现。

RGB 低照增强以 0.25 概率施加，gamma 范围 1.5 至 2.5，增益范围 0.4 至 0.8，使用独立确定性随机流；IR 和 Depth 保持原传感表示。低照策略在训练末期继续启用。HBS 需要训练标注构造掩码，推理完全旁路，不使用测试标签或额外平滑。

2.5 全量训练与权重选择

学生全量训练 64 轮、seed42，双卡 DDP 每卡 batch4、累积 1，有效 batch8。采用图像级类别均衡重采样，原运行每轮 314 次优化更新。最高分 epoch47 为从 0 编号的第 48 个完整训练轮，其 EMA 更新次数为 15072。该权重是全量运行中的中期状态，并非独立验证集选出的最佳轮。

参数	最终全量配置
结构	W424 / D4 / Q300 / OPF1；880×1600
训练	2000 张；64 轮；seed42；两卡×batch4；累积 1
优化器	AdamW；基础 LR1e-4；weight decay1e-4
学习率	warmup2 轮；flat-cosine；flat ratio0.33
梯度与 EMA	BF16；梯度裁剪 0.1；EMA0.998、warmups200
采样与增强	RFS 阈值 0.2、最大重复 4；模态丢弃 0.1；低照概率 0.25
HBS 与蒸馏	clean/HBS 各 0.5；KD 全局 0.5、IR0、Depth2
提交权重	epoch47 EMA；完成 48 轮；15072 次 EMA 更新
推理	原始 G6；FP32；0.25；max100；5 位小数

backbone 学习率为基础值的 0.05 倍，其余预训练检测器参数为 0.1 倍，融合、输入适配、分类头和 HBS 使用基础学习率。正式运行保留完整 64 轮调度，选取 epoch47 不会把学习率周期压缩到 48 轮。归档学生包含 1110 个 EMA 状态张量，保留原精度与全部推理所需参数。

2.6 原始 G6 推理与结果格式

每张图构造一个整图视图与四个 2×2 切片，切片重叠比例 0.2，三模态同步裁剪，每个视图使用 880×1600 输入和同一 epoch47 EMA。FP32 推理保留 top300 候选，过滤位于切片内部边缘 1.5 像素处的截断框；同类跨视图使用 IoU0.6 一对一匹配，坐标按分数加权，簇分数取最大成员值。

仅被切片检出的簇按 0.25 加上原分数超过 0.25 部分的一半进行降分。最后保留置信度不低于 0.25、每图最多 100 框，归一化中心坐标、宽高和分数保留 5 位小数。无目标图仍输出空 TXT。最终包包含 1000 个 TXT、16286 个框，未使用翻转、C1、额外高分辨率或不同模型融合。

三、算法创新点

本作品的贡献主要是针对赛题的组合设计和工程验证：将 RF-DETR 预训练检测器适配为独立三模态分支，通过固定 NAS 结构控制窗口与解码深度；将教师初始化与持续蒸馏分离控制；在融合特征上引入保护前景的 HBS 双视图训练，并保持部署路径简单。RF-DETR、OPF、PKD 和 SET 属于已有研究，本团队不将这些基础模块宣称为原创。

推理侧将同一三模态学生用于整图和切片，结合边缘截断过滤、一对一跨视图匹配及切片独有框降分，在远处目标与额外误检之间作工程折中。输入语义、五位小数序列化和提交级验证贯穿整个流程，减少训练指标与实际提交文件之间的差异。

四、问题与思考

配置与提交	半决赛线上分数
前期 NAS 赢家	54.782
低照全量版本	54.864
HBS＋正常学习率＋低照 epoch31 原始 G6	55.880
同一 HBS 全量运行 epoch47 原始 G6（最终选择）	56.132
epoch47 翻转＋G6＋C1＋高分辨率	55.797

以上为同一半决赛阶段的线上记录，分数由队伍提交后确认。它们记录系统迭代，不构成严格单变量消融：部分运行同时改变了模型、batch 或推理方式。最终选择 56.132 版本，不跨比赛阶段直接比较分数，也不把框数变化解释为精度提升。

半决赛出现新的光照和拥挤分布，验证集与测试集存在域差异。类别均衡能增加稀有类曝光，但不能增加独立场景多样性；全量训练虽利用更多标注，也失去独立早停依据。本轮 epoch47 优于后期候选的记录说明训练损失下降与目标域精度提升并不等价。后续应保留按序列分组验证，并补充多 seed 与类别误差分析。

额外推理增强没有稳定超过原始 G6，因此最终只提交已确认最高分的单模型流程。提高最终置信度可减少输出数量，但对同一组固定预测直接删除低分尾部，不能据此保证插值 AP 提高；竞赛阶段始终以实际评分和受控验证为依据。关于性能收益，本报告只陈述已记录结果，不为未完成的消融或新基座试验推断分数。

作品归档将训练与部署需求分开：代码目录不放数据、权重、环境和服务器凭据；唯一学生权重放在独立目录，保留 SHA256 和原结果包身份。便携入口采用严格状态加载，G6 后处理与原提交记录进行逐文件核验。重新训练受环境和随机性影响，不承诺重新训练后逐位复现线上分数。

五、过程进度

阶段	时间	主要完成内容
基础流程	2026 年 8 月至 9 月	数据处理、三模态训练、教师与 RF 基座适配
结构与蒸馏	2026 年 9 月至 10 月上旬	标签核对、教师全量训练、NAS 与系数对照
半决赛适配	2026 年 10 月下旬	低照、HBS、G6 与训练轮次比较
最终归档	2026 年 10 月 31 日至 11 月 1 日	确定 56.132 版本，归档代码、权重、结果和报告

六、团队分工

姓名	角色	负责内容
刘志轩	方案与实验统筹	总体方案、训练集群管理、配置与线上提交
朱文楦	数据与评估	标签质检、深度语义、采样和误差分析
孙延	模型与复现	融合与蒸馏实现、消融复核、代码与报告整理

七、解题参考

[1] Robinson 等. RF-DETR: Neural Architecture Search for Real-Time Detection Transformers. ICLR2026. https://arxiv.org/abs/2511.09554

[2] Zhao 等. Rethinking Multi-Modal Object Detection from the Perspective of Mono-Modality Feature Learning. 2025. https://arxiv.org/abs/2503.11780

[3] SET: Spectral Enhancement for Tiny Object Detection. CVPR2025 官方实现. https://github.com/HuixinSun/SET

[4] RF-DETR 及 RF-DETR Plus 实现与许可. https://github.com/roboflow/rf-detr

[5] D-FINE 共享兼容组件与许可证. https://github.com/Peterande/D-FINE

参考方法经本赛题训练与推理流程适配，不将公开数据集成绩当成本作品实测成绩。模型、第三方组件与预训练权重按各自许可证使用；技术实现、配置、原始结果和权重身份以材料目录内的归档文件为准。